

강화학습

Week4 HW

Quiz 1 · Quiz 2

1. Quiz 1 — Policy Evaluation

- a. 코드 분석
- b. 다섯 정책의 결과 분석
- c. 정책에 따른 V 변화

2. Quiz 2 — 5×5 GridWorld

- a. 정책 반복 과정 및 최종 결과
- b. 가치 반복 과정 및 최종 결과

3. 전체 결과 비교

Quiz 1

Policy Evaluation

1. Quiz 1 - 환경 및 계산 규칙

0.00 ↑	0.00 ↑	0.00 ↑	0.00 R 1.0 (GOAL)
0.00 ↑		0.00 ↑	1.00 ↑ R -1.0
0.00 ↑	0.00 ↑	0.00 ↑	-0.10 ↑

- GridWorld

3×4 환경 / 시작 (2,0) / 목표 (0,3) / 벽 (1,1)

행동 순서: UP, DOWN, LEFT, RIGHT. 할인율 $\gamma=0.9$, 임
겟값 0.001.

목표 진입 보상 +1, (1,3) 진입 또는 머무름 보상 -1. 경계·
벽에 막히면 현재 칸에 머문다.

목표는 종료 상태로 $V=0$. 그래프의 숫자는 해당 정책을 따
를 때의 기대 할인 보상이다.

1. Quiz 1 - 코드 분석

```
def eval_onestep(pi, V, env, gamma=0.9):
    for state in env.states(): # 각 상태에 접근
        if state == env.goal_state: # 목표 상태에서의 가치 함수는 항상 0
            V[state] = 0
            continue

        action_probs = pi[state] # probs는 probabilities(확률)
        # 의 약자
        new_V = 0

        # 각 행동에 접근
        for action, action_prob in action_probs.items(): # items는 pi(a|s)
            next_state = env.next_state(state, action)
            r = env.reward(state, action, next_state)
            # 새로운 가치 함수
            new_V += action_prob * (r + gamma * V[next_state])

        V[state] = new_V
    return V
```

• One-step Evaluation

각 상태에서 가능한 행동의 보상과 다음 상태 가치를 계산하고 행동 확률로 가중 평균한다.

$$V(s) = \sum \pi(a|s) [r + 0.9V(s')]$$

r 은 현재 칸의 표시 보상이 아니라 이번 행동으로 다음 칸에 들어갈 때 받는 보상이다.

같은 딕셔너리를 순서대로 갱신하므로 이미 갱신한 이웃의 값을 바로 사용한다.

1. Quiz 1 - 코드 분석

```
def policy_eval(pi, V, env, gamma, threshold=0.001):
    while True:
        old_V = V.copy() # 갱신 전 가치 함수
        V = eval_onestep(pi, V, env, gamma)

        # 갱신된 양의 최댓값 계산
        delta = 0
        for state in V.keys():
            t = abs(V[state] - old_V[state])
            if delta < t:
                delta = t

        # 임계값과 비교
        if delta < threshold:
            break
    return V
```

• Iterative Evaluation

현재 정책을 고정하고 one-step evaluation을 반복한다.

갱신 전후 가치 차이의 최댓값 Δ 가 0.001 미만이면 종료한다.

다섯 정책을 각각 독립적으로 평가한다. 정책 ①에서 ⑤로 개선하는 과정은 아니다.

1. Quiz 1 - 결과 분석

0.00 ↑	0.00 ↑	0.00 ↑	0.00 R 1.0 (GOAL)
0.00 ↑		0.00 ↑	1.00 ↑ R -1.0
0.00 ↑	0.00 ↑	0.00 ↑	-0.10 ↑

- ① 위로만 이동 [1, 0, 0, 0]

대부분의 칸은 위쪽 경계나 벽에 막혀 보상 0만 받으므로 $V=0$ 이다.

(1,3)은 바로 목표로 들어가 $V=1$ 이다.

(2,3)은 -1을 받은 뒤 목표 보상 +1을 받아 $V=-1+0.9\times 1=-0.1$ 이다.

시작 상태 $V(2,0)=0$. 목표까지 연결되는 경로가 없다.

1. Quiz 1 - 결과 분석

0.00 ↓	0.00 ↓	0.00 ↓	0.00 R 1.0 (GOAL)
0.00 ↓		0.00 ↓	0.00 ↓ R -1.0
0.00 ↓	0.00 ↓	0.00 ↓	0.00 ↓

- ② 아래로만 이동 [0, 1, 0, 0]

모든 유효 상태의 $V=0$ 이다. 아래로 이동하다가 벽이나 아래쪽 경계에 머문다.

(1,3)에서 출발해도 아래 칸의 보상이 0이므로 $V=0$ 이다.

목표 (0,3)에서 아래로 이동한다고 가정하면 -1이지만, 목표는 종료 상태이므로 추가 행동을 하지 않고 $V=0$ 으로 고정한다.

1. Quiz 1 - 결과 분석

0.00 ←	0.00 ←	0.00 ←	0.00 R 1.0 (GOAL)
0.00 ←		0.00 ←	0.00 ← R -1.0
0.00 ←	0.00 ←	0.00 ←	0.00 ←

- ③ 왼쪽으로만 이동 [0, 0, 1, 0]

목표 반대쪽으로 이동하다가 왼쪽 경계나 벽에 머문다.

목표에도 음수 보상 칸에도 진입하지 않아 모든 유효 상태의 $V=0$ 이다.

②와 이동 방향은 다르지만 받을 보상이 모두 0이라 가치 결과는 같다.

1. Quiz 1 - 결과 분석

0.81 →	0.90 →	1.00 →	0.00 R 1.0 (GOAL)
0.00 →		-9.99 →	-9.99 → R -1.0
0.00 →	0.00 →	0.00 →	0.00 →

- ④ 오른쪽으로만 이동 [0, 0, 0, 1]

위 행에서는 목표에 도달한다. 목표에 가까울수록 $0.81 \rightarrow 0.90 \rightarrow 1.00$ 으로 가치가 커진다.

(1,2)와 (1,3)은 음수 보상 칸에 계속 머물러 -1을 반복해서 받는다.

이론값은 $-1/(1-0.9)=-10$. 계산값 -9.9914는 종료 임계값에 따른 근삿값이다.

시작 상태는 아래 행에서 오른쪽 경계에 머물러 $V=0$ 이다.

1. Quiz 1 - 결과 분석

0.05 ↑	0.13 ↑	0.35 ↑	0.00 R 1.0 (GOAL)
0.04 ↑		0.21 ↑	0.65 ↑ R -1.0
0.04 ↑	0.05 ↑	0.11 ↑	-0.34 ↑

• ⑤ 위쪽 선호 확률적 이동 [0.7, 0.1, 0.1, 0.1]

위 70%, 나머지 방향 각 10%. 그래프는 가장 확률이 높은 위쪽 화살표만 표시한다.

오른쪽으로도 이동할 수 있어 왼쪽 칸에서도 목표 보상을 얻을 가능성이 생긴다. 시작 상태 $V \approx 0.0392$.

(1,3)은 70% 확률로 목표에 진입해 $V \approx 0.6458$ 이다.

(2,3)은 음수 보상 칸에 들어갈 가능성이 높아 $V \approx -0.3449$ 이다.

1. Quiz 1 - 정책에 따른 V 비교

상태	① 위	② 아래	③ 왼쪽	④ 오른쪽	⑤ 위쪽 선호
(0,2)	0	0	0	1	0.3513
(1,2)	0	0	0	-9.9914	0.2085
(1,3)	1	0	0	-9.9914	0.6458
(2,3)	-0.1	0	0	0	-0.3449
시작 (2,0)	0	0	0	0	0.0392

• V가 변하는 이유

정책이 바뀌면 목표까지의 경로·이동 시간·음수 보상 횟수가 달라진다.

같은 칸의 보상 표시는 고정되어 있어도 미래 보상의 기대값 V는 달라진다.

⑤가 시작 상태에서 다섯 정책 중 가장 높다. 전체 가능한 정책 중 최적이라는 의미는 아니다.

1. Quiz 1 - V 계산 예시

0.05 ↑	0.13 ↑	0.35 ↑	0.00 R 1.0 (GOAL)
0.04 ↑		0.21 ↑	0.65 ↑ R -1.0
0.04 ↑	0.05 ↑	0.11 ↑	-0.34 ↑

• (0,2)와 (2,3)의 변화

(0,2): ④는 즉시 목표에 들어가 $V=1$. ⑤는 즉시 오른쪽으로 갈 확률이 10%이고 경계에 머무르는 시간이 길어 $V \approx 0.3513$ 으로 감소한다.

⑤의 $V(0,2) = 0.7[0.9V(0,2)] + 0.1[0.9V(1,2)] + 0.1[0.9V(0,1)] + 0.1 \times 1$.

(2,3): ①은 $-1 + 0.9 \times 1 = -0.1$. ⑤에서는 다음 상태 (1,3)의 가치도 0.6458로 낮아져 최종 $V \approx -0.3449$ 가 된다.

위쪽 이동 확률을 줄였다고 반드시 V 가 높아지지는 않는다. 다음 상태의 미래 보상도 함께 달라진다.

Quiz 2

Policy Iteration · Value Iteration

2. Quiz 2 - 5×5 환경

0.00	0.00	0.00	0.00	0.00
			R -1.0	R 1.0 (GOAL)
0.00	0.00	0.00	0.00	0.00
0.00			0.00	0.00
0.00	0.00	0.00	0.00	0.00
0.00				R -1.0
0.00	0.00	0.00	0.00	0.00

• 환경 설정

시작 (4,0), 목표 (0,4), 벽 (2,1)·(2,2). 좌표는 (행, 열), 0 부터 시작한다.

폭탄 (0,3)·(3,4)에 진입하면 -1, 목표에 진입하면 +1. 나머 지는 0.

폭탄은 Q1과 같은 비종료 칸으로 해석했다. 목표만 종료 상 태이며 V=0이다.

할인율 0.9, 임계값 0.001. 동일한 환경에서 두 알고리즘을 비교한다.

2. Quiz 2 - 정책 반복 코드 분석

```
def policy_iter(env, gamma, threshold=0.001, is_render=True):
    pi = defaultdict(lambda: {0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25})
    V = defaultdict(lambda: 0)

    while True:
        V = policy_eval(pi, V, env, gamma, threshold) # 평가
        new_pi = greedy_policy(V, env, gamma) # 개선

        if is_render:
            env.render_v(V, pi)

        if new_pi == pi: # 갱신 여부 확인
            break
        pi = new_pi

    return pi
```

• Policy Iteration

균등 무작위 정책으로 시작한다.

현재 정책을 임의값까지 평가한 다음, $r+0.9V(s')$ 가 가장 큰 행동으로 정책을 개선한다.

개선 후 정책이 같으면 종료한다. 그래프는 평가 직후의 가치와 평가에 사용한 현재 정책을 표시한다.

하나의 step 안에 정책 평가를 위한 여러 순회가 포함된다.

2. Quiz 2 - 가치 반복 코드 분석

```
def value_iter_onestep(V, env, gamma):
    for state in env.states(): # 모든 상태에 차례로 접근
        if state == env.goal_state: # 목표 상태에서의 가치 함수는 항상 0
            V[state] = 0
            continue

        action_values = []
        for action in env.actions(): # 모든 행동에 차례로 접근
            next_state = env.next_state(state, action)
            r = env.reward(state, action, next_state)
            value = r + gamma * V[next_state] # 새로운 가치

            action_values.append(value)

        V[state] = max(action_values) # 최댓값 추출
    return V
```

• Value Iteration

정책의 확률 평균 대신 모든 행동 중 최댓값으로 V 를 갱신한다.

$$V(s) = \max [r + 0.9V(s')]$$

전체 상태를 한 번 갱신한 결과를 매 단계 저장한다. 최대 변화량이 0.001 미만이면 종료한다.

V 가 수렴한 뒤 탐욕 정책을 한 번 계산한다. 동일 순회에서 최신 값을 사용한다.

2. Quiz 2 - 정책 반복 과정

-0.21 ↑ ↓ ← →	-0.34 ↑ ↓ ← →	-0.66 ↑ ↓ ← →	-0.38 ↑ ↓ ← → R -1.0	0.00 R 1.0 (GOAL)
-0.19 ↑ ↓ ← →	-0.28 ↑ ↓ ← →	-0.46 ↑ ↓ ← →	-0.64 ↑ ↓ ← →	-0.14 ↑ ↓ ← →
-0.14 ↑ ↓ ← →			-0.75 ↑ ↓ ← →	-0.94 ↑ ↓ ← →
-0.17 ↑ ↓ ← →	-0.27 ↑ ↓ ← →	-0.49 ↑ ↓ ← →	-0.99 ↑ ↓ ← →	-1.26 ↑ ↓ ← → R -1.0
-0.17 ↑ ↓ ← →	-0.26 ↑ ↓ ← →	-0.45 ↑ ↓ ← →	-0.79 ↑ ↓ ← →	-1.29 ↑ ↓ ← →

- step_00

시작 상태 가치: -0.17333

네 방향을 각각 25%로 선택하는 무작위 정책을 평가한 결과다. 폭탄에 진입하거나 머무를 가능성이 있어 목표를 제외한 모든 상태의 가치가 음수다. 시작 상태는 -0.17333이며, 폭탄 아래 (4,4)는 -1.29392로 특히 낮다. 이 가치를 기준으로 다음 정책을 개선한다.

2. Quiz 2 - 정책 반복 과정

-0.01 ↓	-0.01 ←	-0.01 ←	1.00 → R -1.0	0.00 R 1.0 (GOAL)
-0.01 ↓	-0.01 ←	-0.01 ←	0.90 →	1.00 ↑
-0.01 →			0.81 ↑	0.90 ↑
-0.01 ↑	-0.01 ←	-0.01 ←	-0.01 ←	0.81 ↑ R -1.0
-0.01 ↑	-0.01 ←	-0.01 ←	-0.00 ←	-0.00 ←

• step_01

시작 상태 가치: -0.00677

첫 개선으로 목표 가까이에서는 목표를 향하는 행동이 선택된다. (0,3)과 (1,4)는 1, (1,3)은 0.9가 된다. 하지만 왼쪽에서는 폭탄을 피하는 행동이 벽에 막히거나 목표와 연결되지 않아 가치가 거의 0이다. 시작 상태는 -0.00677까지 개선된다. 작은 음수는 이전 가치에서 출발해 임곗값까지 평가한 근사 오차이며, 보상 없이 계속 머무르는 상태의 정확한 가치는 0이다.

2. Quiz 2 - 정책 반복 과정

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.48 ↓			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
-0.00 →	-0.00 →	-0.00 →	-0.00 →	-0.00 →

- step_02

시작 상태 가치: -0.00236

다음 개선으로 위쪽과 가운데 아래 행에 목표까지 이어지는 경로가 생긴다. (1,2)는 0.81, (3,3)은 0.729로 상승한다. 그러나 맨 아래 행은 오른쪽으로만 이동하다가 (4,4)의 경계에 머무는 정책이므로 아직 목표에 도달하지 못한다. 시작 상태는 약 -0.00236으로 0에 가깝다.

2. Quiz 2 - 정책 반복 과정

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 ↑	0.53 ↑	0.59 ↑	0.66 ↑	-0.00 →

• step_03

시작 상태 가치: 0.47830

맨 아래 행의 (4,0)부터 (4,3)까지 화살표가 위쪽으로 바뀌어 목표 경로와 연결된다. 시작 상태 가치는 0.47830이 된다. (2,0)도 아래로 우회하던 경로에서 위로 가는 더 짧은 경로로 바뀌어 0.47830에서 0.59049로 상승한다. 다만 (4,4)는 여전히 오른쪽 경계에 머물러 약 -0.00191이다.

2. Quiz 2 - 정책 반복 과정

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

• step_04

시작 상태 가치: 0.47830

오른쪽 아래 (4,4)가 왼쪽 이동으로 바뀌어 폭탄을 피해 목표에 도달하며 가치가 0.59049로 상승한다. 아래 행의 일부 칸은 위쪽 대신 오른쪽을 선택하지만 같은 길이의 최적 경로이므로 가치가 변하지 않는다. 개선 후 정책이 현재 정책과 같아져 반복을 종료한다.

2. Quiz 2 - 정책 반복 과정

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

- final

시작 상태 가치: 0.47830

확정된 정책을 다시 평가한 최종 결과다. step_04와 같은 최적 가치와 정책이며, 시작 상태에서 폭탄을 피하는 8번의 이동으로 목표에 도달한다.

2. Quiz 2 - 가치 반복 과정

0.00	0.00	0.00	0.00	0.00
			R -1.0	R 1.0 (GOAL)
0.00	0.00	0.00	0.00	0.00
0.00			0.00	0.00
0.00	0.00	0.00	0.00	0.00
				R -1.0
0.00	0.00	0.00	0.00	0.00

- step_00

시작 상태 가치: 0.00000

모든 상태의 가치를 0으로 초기화한 상태다. 아직 목표 보상이 다른 상태에 반영되지 않았으며 정책도 정하지 않았다.

2. Quiz 2 - 가치 반복 과정

0.00	0.00	0.00	1.00 R -1.0	0.00 R 1.0 (GOAL)
0.00	0.00	0.00	0.00	1.00
0.00			0.00	0.90
0.00	0.00	0.00	0.00	0.81 R -1.0
0.00	0.00	0.00	0.00	0.00

- step_01

시작 상태 가치: 0.00000

첫 갱신에서 목표로 바로 이동하는 (0,3)과 (1,4)의 가치가 1이 된다. 행 순서대로 갱신하면서 최신 값을 바로 사용하므로 (2,4)는 0.9, (3,4)는 0.81까지 같은 순회에서 갱신된다. 시작 상태는 아직 0이다.

2. Quiz 2 - 가치 반복 과정

0.00	0.00	0.00	1.00 R -1.0	0.00 R 1.0 (GOAL)
0.00	0.00	0.00	0.90	1.00
0.00			0.81	0.90
0.00	0.00	0.00	0.73	0.81 R -1.0
0.00	0.00	0.00	0.66	0.59

• step_02

시작 상태 가치: 0.00000

목표 보상이 오른쪽의 3열과 맨 아래 오른쪽으로 전달된다. (1,3)은 0.9, (2,3)은 0.81, (3,3)은 0.729, (4,3)은 0.65610이 된다. (4,4)는 폭탄 위로 이동하는 대신 왼쪽을 선택하는 가치가 반영되어 0.59049가 된다.

2. Quiz 2 - 가치 반복 과정

0.00	0.00	0.00	1.00 R -1.0	0.00 R 1.0 (GOAL)
0.00	0.00	0.81	0.90	1.00
0.00			0.81	0.90
0.00	0.00	0.66	0.73	0.81 R -1.0
0.00	0.00	0.59	0.66	0.59

- step_03

시작 상태 가치: 0.00000

양수 가치가 2열로 확장된다. (1,2)는 0.81, (3,2)는 0.65610, (4,2)는 0.59049가 된다. 두 벽 때문에 보상은 벽을 통과하지 않고 위쪽과 아래쪽 경로를 통해 전달된다.

2. Quiz 2 - 가치 반복 과정

0.00	0.00	0.73	1.00	0.00
			R -1.0	R 1.0 (GOAL)
0.00	0.73	0.81	0.90	1.00
0.00			0.81	0.90
0.00	0.59	0.66	0.73	0.81
			R -1.0	
0.00	0.53	0.59	0.66	0.59

- step_04

시작 상태 가치: 0.00000

1열에도 목표까지의 가치가 전달된다. (1,1)은 0.729, (3,1)은 0.59049, (4,1)은 0.53144가 된다. (0,2)는 바로 오른쪽 폭탄으로 진입하기보다 아래로 우회하는 가치 0.729를 갖는다.

2. Quiz 2 - 가치 반복 과정

0.00	0.66	0.73	1.00	0.00
			R -1.0	R 1.0 (GOAL)
0.66	0.73	0.81	0.90	1.00
0.59			0.81	0.90
0.53	0.59	0.66	0.73	0.81
				R -1.0
0.48	0.53	0.59	0.66	0.59

- step_05

시작 상태 가치: 0.47830

목표 보상이 왼쪽 0열과 시작 상태까지 전달된다. (1,0)은 0.65610, (2,0)은 0.59049, 시작 상태 (4,0)는 0.47830 이 된다. 다만 순회 초반에 처리되는 (0,0)은 아직 갱신 전 이웃 값을 사용해 0이다.

2. Quiz 2 - 가치 반복 과정

0.59	0.66	0.73	1.00 R -1.0	0.00 R 1.0 (GOAL)
0.66	0.73	0.81	0.90	1.00
0.59			0.81	0.90
0.53	0.59	0.66	0.73	0.81 R -1.0
0.48	0.53	0.59	0.66	0.59

- step_06

시작 상태 가치: 0.47830

남아 있던 (0,0)이 오른쪽 이웃의 가치를 사용해 0.59049로 바뀐다. 모든 유효 상태의 가치가 최적값에 도달한다. 그 다음 한 번 더 갱신하여 변화량이 0임을 확인하고 반복을 종료한다.

2. Quiz 2 - 가치 반복 과정

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

- final

시작 상태 가치: 0.47830

수렴한 가치에서 각 행동의 보상 + $0.9 \times$ 다음 상태 가치를 비교해 탐욕 정책을 구한다. 여기서 처음으로 화살표를 표시한다. 정책 반복의 최종 결과와 가치·정책이 일치한다.

2. Quiz 2 - 최종 가치 및 정책

정책 반복

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

가치 반복

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

두 방법의 최종 가치·정책이 일치하며, 시작 상태 $V(4,0) \approx 0.47830$ 이다.

3. 정책 반복과 가치 반복 비교

비교 항목	정책 반복	가치 반복
가치 갱신	정책 확률로 가중 평균	행동별 값 중 최댓값
한 step	정책 평가 수렴 + 정책 개선	전체 상태 한 번 갱신
정책 계산	바깥 반복마다 개선	가치 수렴 후 최종 계산
종료 기준	정책이 더 이상 변하지 않음	최대 가치 변화 < 0.001
이번 실행	평가·개선 5회	갱신 7회 (마지막은 변화 확인)

- 단계 수와 계산량

정책 반복은 초기의 음수 가치가 정책 개선에 따라 양수로 바뀐다.

가치 반복은 목표 주변의 양수 가치가 왼쪽·시작 상태로 점차 전달된다.

한 step의 계산량이 다르므로 그래프 수만으로 실행 속도를 비교할 수 없다.

3. 전체 결과 분석

0.59 →	0.66 →	0.73 ↓	1.00 → R -1.0	0.00 R 1.0 (GOAL)
0.66 →	0.73 →	0.81 →	0.90 →	1.00 ↑
0.59 ↑			0.81 →	0.90 ↑
0.53 →	0.59 →	0.66 →	0.73 ↑	0.81 ↑ R -1.0
0.48 →	0.53 →	0.59 →	0.66 ↑	0.59 ←

• 결과 해석

Quiz 1: 같은 환경에서도 어떤 정책을 따르는지에 따라 V 가 달라진다. 목표 접근, 보상 지연, 반복 손실을 함께 고려해야 한다.

Quiz 2: 두 알고리즘은 다른 계산 과정으로 동일한 최적 가치와 정책에 도달한다.

시작 상태에서 폭탄을 피하는 8번의 이동으로 목표에 도달한다. 마지막 이동에서만 +1을 받아 $V=0.9^7 \approx 0.47830$.

폭탄 칸 자체의 V 도 양수일 수 있다. 그 칸에서 출발해 앞으로 받을 보상을 평가하기 때문이다. 목표 $V=0$ 은 종료 규칙이다.